YelpZip 기반
가짜 리뷰 탐지 GNN

Multi-relation GNN with Partition Aggregation



2026 학술제 본선

Test PR-AUC 0.6878 Macro-F1 0.7562

경희대학교 CODE

강동균 · 김형민 · 이동현

Part 1

Introduction

문제 정의와 접근 방법

Part 1

가짜 리뷰는 텍스트가 아니라 네트워크 문제이다

단일 리뷰 문장으로는 정상과 구분이 어렵고, 관계 구조에서 패턴이 드러난다

1-1 : Why GNN? 세 가지 구조적 어려움이 동시에 작용

01

클래스 불균형

원본 가짜 리뷰 비율 ≈ 13%
전부 정상이라 예측해도 Accuracy 87%
Accuracy는 부적합 지표

02

관계적 패턴

단일 텍스트만으론 정상과 유사
같은 작성자·상품·시점에 몰리는
조직적 패턴으로 드러난다

03

Camouflage

가짜 리뷰는 정상처럼 위장
평균 기반 GNN은 정상 이웃에
섞이면 fraud signal 희석

Source: YelpZip Dataset (Rayana & Akoglu, 2015)

Part 1

전체 흐름: 데이터부터 대시보드까지

샘플링·피처·관계·모델·평가가 하나의 논리로 연결되어 있다

1-2 : Pipeline Overview 7단계 흐름 + 3축 가치



데이터 보존

Block 단위 샘플링으로 그래프 연결성 유지

다중 신호

행동·별점·시간·텍스트 4개 축을 relation으로 분리

운영 연계

단순 분류가 아닌 대시보드 기반 검수 시스템

핵심 차별점: 텍스트는 노드 피처가 아닌 net_utu 관계로 분리하여 그래프 구조 신호로 활용

Source: Team CODE Analysis

Part 2

Data & Sampling

2014년 단일 연도 · 구조 보존형 샘플링 · 24-dim 피처

Part 2

왜 2014년 한 해만 사용했는가

데이터 규모, 연중 변동 반영, 시간적 이질성 완화의 세 가지 근거

2-1 : Why 2014? 단일 연도 선택의 정량적 근거

01 데이터 규모 충분

2014년 = 수집 기간 내 리뷰 수·사용자 활동이 가장 활발한 연도. 단일 연도만으로 18만 건 확보.

02 연중 변동 반영

특정 월 편중을 피하기 위해 12개월 전체 사용. 캠페인·시즌 이벤트 단기 편향 통제.

03 시간적 이질성 완화

전체 11년 데이터의 플랫폼 정책·문화 변화 누적 효과를 단일 연도로 제한.

2014 STATS

180,659	전체 리뷰 수
101,729	사용자 수
4,529	상품 수
12.66 %	가짜 리뷰 비율
33,161	product-month 블록

NOTE 단일 연도 사용 → 시간 일반화 검증 부재 (한계 항목에서 보완 계획 제시)

Source: YelpZip Dataset (2004-2015), Team Analysis

Part 2 구조 보존형 샘플링: Block + User Bridge

랜덤이 아니라 그래프 연결성을 보존하는 단계적 접근

2-2 : Sampling Strategy 방법 A → 방법 B → User Bridge 3단계

STEP 1

방법 A — 구조 조건 필터

n_reviews ≥ 20 · n_users ≥ 5 · 단일 상품 ≤ 20%

1,420 blocks | 코어 노드 48,071

↓

STEP 2

방법 B — 층화 균등 추출

25개 활성 층 (year_month × size)에서 균등 추출, 상위 57개 선택

846 blocks | 코어 노드 35,418

↓

BRIDGE

User Bridge — 사용자 관계 보강

코어 사용자의 외부 리뷰 최대 3건 추가 (label 미사용)

+ 11,129 nodes | R-U-R coverage 39% → 69%

최종 학습 샘플

전체 노드	**46,547**
ㄴ 코어	**35,418**
ㄴ Bridge	**11,129**
가짜 비율	**12.87%**
R-T-R cov	**90.26%**
R-U-R cov	**69.46%**
R-S-R cov	**82.63%**

Source: Team CODE Analysis

Part 2

Sampling 보완 논리

Base : n_reviews ≥ 20 · n_users ≥ 5 · 단일 상품 ≤ 20% / 다른 임계값으로 통계량 비교 검토

조건	N_reviews	N_users	Prod_share	블록 수	노드 수	가짜 비율	RTR COV	RSR COV	RUR COV	TOP 1 Share
Loose	10	3	0.30	4,938	94,477	0.1158	1.0000	0.9948	0.5226	0.0203
Medium-loose	15	4	0.25	2,496	66,004	0.1224	1.0000	0.9968	0.4766	0.0291
Base	20	5	0.20	1,420	48,071	0.1311	1.0000	0.9981	0.4289	0.0400
Medium-strict	30	7	0.15	610	29,116	0.1529	1.0000	0.9991	0.3573	0.0660
Strict	50	10	0.10	151	11,467	0.2022	1.0000	0.9993	0.2274	0.0965

가짜 비율과 coverage의 일관성

적절한 노드 규모



핵심 특성 왜곡 x

Source: YelpZip Dataset (2004-2015), Team Analysis

Part 2

24차원 Hand-crafted Feature — 5개 그룹

고차원 텍스트 임베딩 대신 해석 가능한 변수로 설계

2-3 : Node Feature Design 도메인 해석 가능성 우선

USER (7)	PROD (4)	DEV (3)	TEXT (7)	TIME (3)
review_count	prod_review_count	deviation_from_prod	char_len	review_month
avg_rating	prod_avg_rating	deviation_from_user	word_count	review_dayofweek
rating_std	prod_rating_std	rating_is_extreme	unique_word_ratio	prod_same_day_count
day_gap	prod_unique_user		exclamation	
same_day_count			question	
unique_prod			uppercase	
first_review			digit_ratio	

핵심 · StandardScaler 적용 · 모든 변수가 도메인 해석 가능 → 대시보드 Reason Code와 직접 연결

Source: Team CODE Analysis

Part 3

Model

4종 Relation Graph · PMP · Partition Aggregation

Part 3

4종 관계로 가짜 리뷰의 4가지 축을 분리 학습

텍스트는 노드 피처가 아닌 net_utu relation으로 분리

3-1 : Multi-relation Graph Design 행동·별점·시간·텍스트 4축

Relation	축 (Axis)	연결 기준 (Edge Condition)	포착하는 Fraud Signal
net_upu	행동	같은 user_id	작성자 반복 행동 / 일관된 이상 패턴
net_usu	별점	같은 prod_id + 같은 rating	Rating homophily / 평점 몰아주기·공격
net_uvu	시간	같은 prod_id + 같은 month	특정 상품 시간적 burst / 캠페인성 어뷰징
net_utu	텍스트	char n-gram cos ≥ 0.4	템플릿 재사용 / 복사·붙여넣기 변형

핵심 · 텍스트 임베딩을 노드 피처가 아닌 별도 관계(net_utu)로 분리한 이유 = 관계 정보가 텍스트 암기에 가려지는 것을 방지

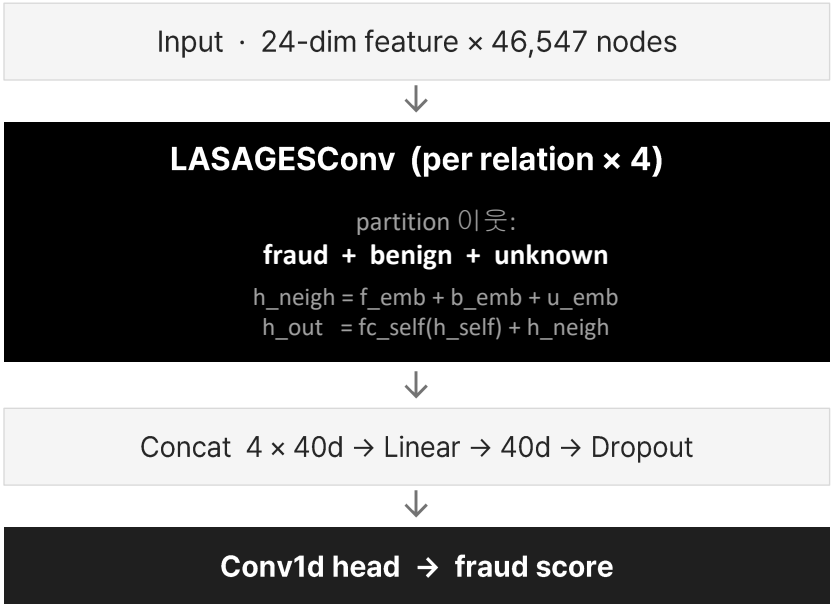
Source: Inspired by CARE-GNN (Dou et al., 2020)

Part 3

PMP 모델 아키텍처

LA-SAGE-S 백본 + Partition Aggregation · 1-hop · full_neighbors · 4 relation

3-2 : Architecture 얕은 GNN + Multi-relation + Partition 전략



설계 의도

- **1-hop 얕은 GNN**
  over-smoothing 회피, fraud signal 보존
- **full_neighbors = True**
  sampling 분산 제거, 학습 안정화
- **relation_agg = concat**
  4개 축 신호를 독립 학습 후 결합
- **관계별 hidden = 40d**
  160d → 40d 압축, 9.5M 엣지 처리 가능

Source: Built upon GraphSAGE (Hamilton et al., 2017) + PMP family

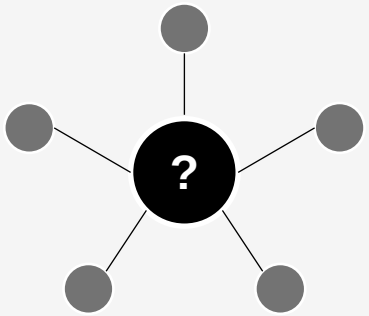
Part 3

이웃을 제거하지 않고 분리해서 사용한다

Camouflage 대응의 핵심: 정상 이웃도 정보, 모르는 이웃도 정보

3-3 : Partition Aggregation fraud / benign / unknown 분리

일반 GNN의 문제



정상 이웃 평균 → fraud signal 희석

PMP의 해결



h_neigh = f_emb + b_emb + u_emb

각 partition에 별도 transformation 적용

핵심 · 가짜 리뷰가 위장할수록, 그 위장 패턴 자체가 모델의 추가 단서가 된다

Source: Inspired by PMP-family for camouflage-aware GNN

Part 3

왜 Accuracy가 아닌 PR-AUC인가

Focal Loss (불균형) + Pairwise Ranking Loss (ranking 목적 정렬) 결합

3-4 : Loss & Evaluation 클래스 불균형 + ranking objective

Focal Loss

쉬운 샘플의 영향력 ↓ 어려운 fraud 샘플 ↑

→ 클래스 불균형 (13%) 대응

focal_gamma = 2.0

Pairwise Ranking Loss

fraud score > benign score 강제

→ PR-AUC ranking 목적과 직접 정렬

ranking_alpha = 0.5, margin = 1.0

Accuracy의 함정

가짜 비율 13% → 모두 정상이라 예측해도 Accuracy = 87%

→ PR-AUC는 positive(가짜) class의 ranking 품질을 직접 평가 · 불균형에 가장 강건

monitor = ap_gnn (validation AP 기준 early stopping)

Source: Focal Loss (Lin et al., 2017)

Part 4

Results

PR-AUC 0.6878 · 4-View Dashboard · Network Visualization

Part 4

PMP 최종 성능

Test PR-AUC 0.6878 · Macro-F1 0.7562 · ROC-AUC 0.9059 (best epoch 30, seed 1234)

4-1 : Performance Results Validation ↔ Test 일관성 확보

0.6878	0.7562	0.9059	0.5881
Test PR-AUC	**Test Macro-F1**	**Test ROC-AUC**	**Test Fraud F1**
valid 0.6780	valid 0.7506	valid 0.9063	개선 여지

결과 해석

01 Valid ↔ Test 차이 0.01 이내 → 과적합 없음

02 ROC-AUC 0.90 vs PR-AUC 0.68 → ROC가 다소 낙관적, PR-AUC가 1차 기준

03 Fraud F1 0.60 → 자동 차단보다 운영자 검수 보조 시스템으로 적합

Source: Team CODE Training Log (seed=1234, best epoch 30)

Part 4 정상 네트워크와 사기 네트워크의 구조적 대비

본 view는 다음 세 layer를 합성하여 화면에 표시한다.

4-2 : Dashboard Design Streamlit 기반 MVP 구현

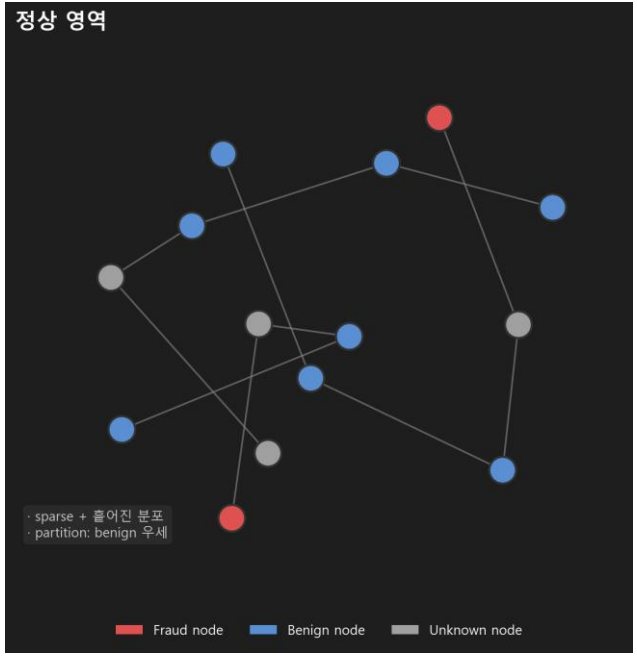
Layer 1	**노드 색상: fraud score 0~1에 대해 연속 색상 매핑** : 운영자는 한 눈에 어떤 영역에 고위험노드가 군집을 이루는지 확인.
Layer 2	**Partition 표시: PMP가 fraud/benign/unknown 분류 결과를 색상으로 표시** : Partiton aggregation 동작을 시각적으로 드러내는 핵심요소.
Layer 3	**엣지 종류: 4종 relation을 서로 다른 색/점선/실선 으로 구분한다** : **net_upu** → 같은 사용자의 반복 행동 **net_uvu** → 시간적 burst임을 즉시 식별 가능.

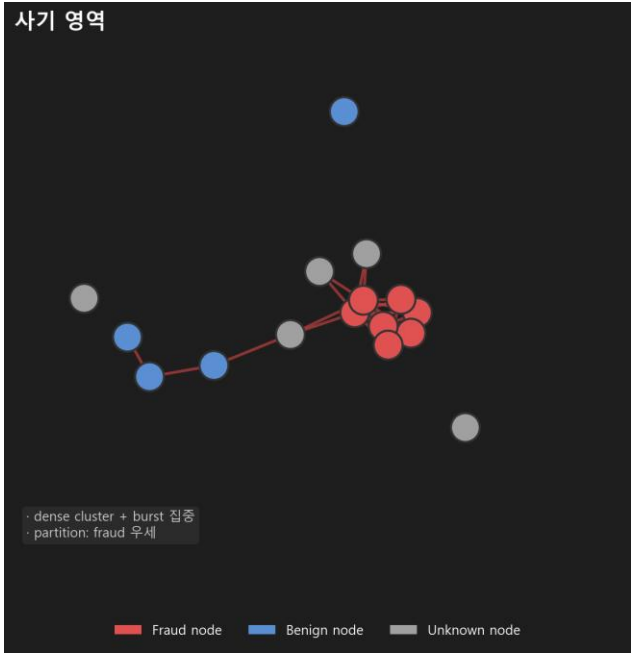
Part 4

정상 네트워크와 사기 네트워크의 구조적 대비

노드 밀도 · 엣지 구성 · partition 분포가 서로 다르게 나타난다

4-3 : Network Visualization Normal vs Fraud 시각적 검증





https://codegnn-project.streamlit.app/

Part 5

Wrap Up

운영 활용 방안 · 한계 인정

Part 5

운영 활용 방안과 한계 인정

대시보드를 활용한 3가지 실무적 활용 방안 검토

5-1 : Use Cases & Limits 실효성과 정직성 동시 확보

운영 활용 방안

01 검수 트리아지 — PR 곡선 기반 임계값 정책

02 네트워크 뷰 — R-U-R 클러스터 기반 연쇄 탐지

03 임베딩 산점도 — 경계 노드 레이블링 후보 선정

한계 인정

01 성능 절대치 : Fraud F1 0.59, Precision 50% (자동 차단 부족)

02 학습 안정성 : Ranking Loss 폭주 (epoch 43~46)
+ 단일 seed 분산 미측정

03 데이터 범위 : 2014 단일 연도 일반화 미검증 + 소규모 블록 누락

우리의 메시지

가짜 리뷰를 텍스트가 아니라 관계 구조로 다시 정의했고, 운영자 보조 시스템으로 실제 활용 가능하다

Source: Team CODE Strategic Analysis

Q & A

감사합니다

경희대학교 CODE · 강동균 · 김형민 · 이동현